

Licenciatura em Ciência de Dados Análise Exploratória de Dados

Ano Letivo 2021/2022

31 de março de 2022

Ecologia

Caso Prático 10



Grupo 10, CDA1

Docentes

Madalena Ramos

Luís Junqueira

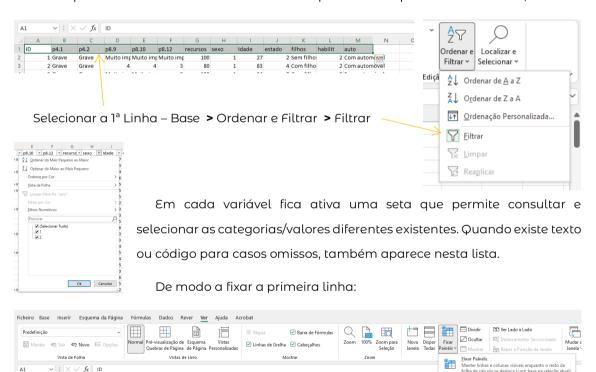
André Silvestre N°104532 | Diogo Catarino N°104745 Eduardo Silva N°104943 | Francisco Gomes N°104944

CP10 Ecologia | Passo a Passo das Tarefas

I. Excel

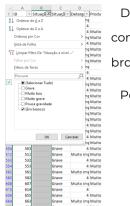
Antes de iniciar as tarefas propostas, de forma a salvaguardar e potenciar a análise estatística dos dados, decidimos efetuar algumas etapas de boas práticas no Excel, entre as quais, duplicámos o ficheiro de dados, de forma a trabalhar sobre a cópia e guardar sempre a fonte de dados original; retirámos as informações de contexto que podem estar a enquadrar as tabelas de dados/base de dados; identificámos na primeira linha o nome das variáveis de trabalho, e substituímo-las pelas etiquetas respetivas; fixámos a visualização da primeira linha, para ser mais prático ver os dados ao longo da folha; e aplicámos o filtro a todas as variáveis.

1°. Aplicar o filtro a todas as variáveis e apresentar a primeira linha fixa;



Ver > Fixar Painéis > Fixar Linha de Cima

2°. Atribuir um código de não resposta a uma variável com valores omissos;



De modo a substituir os valores omissos de uma única variável, começamos por filtrar a coluna, selecionando apenas os valores "(£m branco)".

Posteriormente: Base > Localizar e selecionar > Substituir



A fim de facilitar o uso deste Excel no R, decidimos substituir os valores omissos em todas as variáveis. Para isso selecionamos o conjunto de dados e repetimos o procedimento anterior.

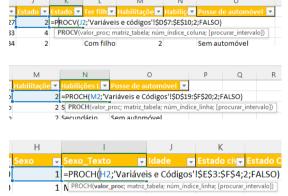


3°. Atribuir texto às categorias de uma variável que tenha códigos;

Nas variáveis "Estado Civil", "Habilitações Literárias" e "Sexo" estão presentes os códigos e não os nomes respetivos e, uma vez que existe uma tabela de codificação de correspondência na folha "Variáveis e Códigos", é possível proceder à descodificação.

No caso do "Estado Civil", como a tabela de correspondência está na vertical, a função que usámos foi a **PROCV()**, enquanto que nas "Habilitações Literárias" e do "Sexo" a tabela de correspondência encontra-se na horizontal pelo o que usámos a função **PROCH()**.

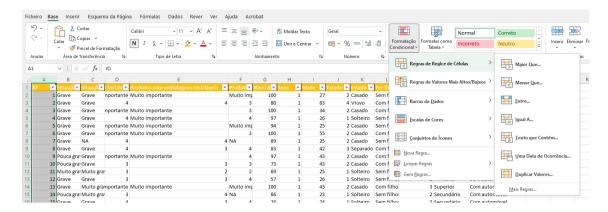
Para tal, inserimos uma coluna à direita de cada uma das variáveis, clicámos na primeira



célula e inserimos a fórmula com a função correspondente, sendo que os atributos colocados em ambas foram (célula com o código que se pretende substituir; seleção da tabela de correspondências sem títulos e com as células fixas; nº da coluna da tabela onde deve ser lida a correspondência; FALSO -correspondência exata)

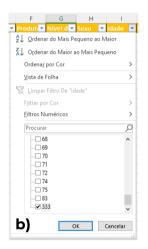
De seguida, copiámos a fórmula para as restantes células da coluna e atribuímos o novo nome à nova variável (coluna).

4°. Corrigir possíveis erros;



Inicialmente de forma a verificar que todos os inquéritos respondidos são únicos, averiguamos que não havia linhas duplicadas uma vez que nenhum dos ID's se repetia. Para constatar este facto, selecionamos a coluna dos ID's e usamos a Regra de Formatação Condicional de Realce de Células "Duplicar Valores...".







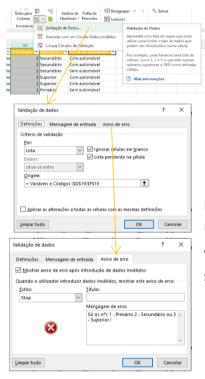
Seguidamente, através da utilização dos filtros e da análise generalizada aos dados que nos foram cedidos, verificou-se se as categorias/valores fazem sentido de acordo com a variável, e detetámos 3 erros:

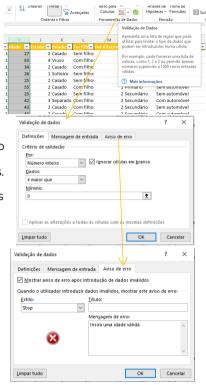
- **a)** o valor 800 no "Nível de preocupação com a destruição de recursos naturais", uma vez que a escala aplicada é de 0 a 100. Sendo assim o valor inserido não faz sentido, e consideramos que o valor correto seria 80;
- **b)** os valores 333 na "Idade", e tal como no anterior, consideramos que o registo foi mal feito e que o valor correto seria o 33;
- c) os valores 9 na variável no "Estado Civil", sendo que os códigos apenas contemplam os números 1 a 4. Neste caso, optamos por converter os valores em NA (não respostas), dado que não é possível corrigir este valor.

5°. Criar regra de validação para duas variáveis: uma quantitativa e outra qualitativa;

Existe a possibilidade de limitar os valores/texto a inserir ou depois de inseridos, visualizar as situações de erro. Para tal, selecionamos a coluna das variáveis escolhidas ("Idade" – variável quantitativa - e "Habilitações Literárias" – variável qualitativa).

Primeiro, selecionámos a coluna da "Idade", fomos ao separador Dados > Validação de Dados > Definições. Limitámos os *inputs* a n°s maiores do que 0 e para valores inferiores um Aviso de Erro "Insira uma idade válida".





Já nas "Habilitações Literárias", realizámos o mesmo procedimento, mas limitámos as respostas aos valores 1 a 3 tal como é o código desta variável. Caso seja introduzido um valor diferente, apresenta o aviso: "Só os nºs 1 - Primário 2 - Secundário ou 3 - Superior!".

6°. Construir uma tabela de frequências absolutas com funções de contagem e cálculo de percentagens;

A fim de contruir uma tabela de frequências absolutas, criámos uma nova folha de cálculo denominada "Tabelas de Frequências"; copiámos a lista de categorias da folha "Variáveis e Códigos"; posteriormente, na célula à direita de cada categoria calculámos as contagens condicionadas, frequências absolutas com a função



CONTAR.SE(), fixámos as células correspondentes à coluna de dados a contar ("Sexo") e copiámos a fórmula para as células restantes.

De seguida, criámos uma última linha com o Total – função **SOMA()**.

Para calcular as frequências absolutas, criámos uma coluna à direita com o cálculo da %, tal como ilustrado, e colocámos o estilo de percentagem na célula.

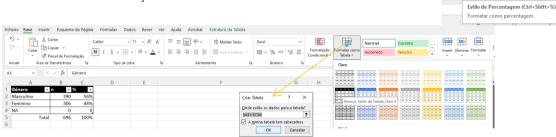
Masculino 390 306 Feminino =SOMA(B2:B4) SOMA(nú В Género 390 = B2/\$B\$5 Masculino 306 Feminino 44% NA 0 0 Total 696 100%

₩ × % 000 €0 .00

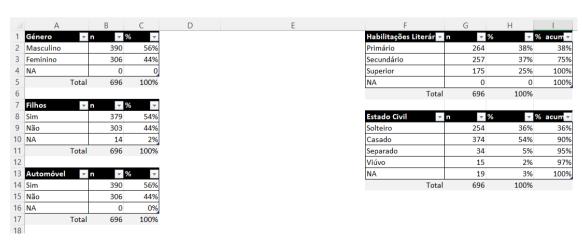
Género

В

Após calcular, e de modo a tornar a tabela de fácil leitura decidimos formatar os cabeçalhos e linhas envolventes de forma automática com a função de "Formatar como Tabela".



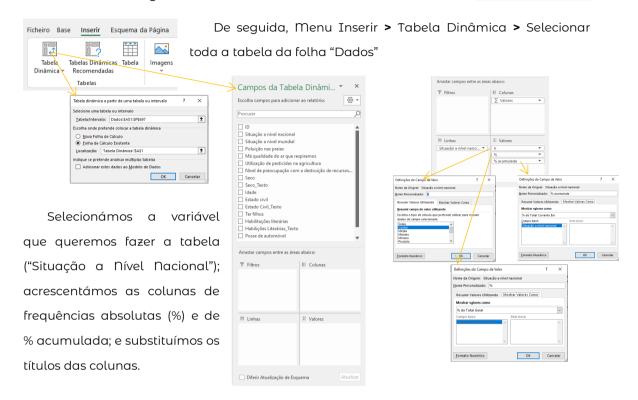
Repetimos estes procedimentos para as restantes variáveis que refletem a caracterização dos inquiridos da base de dados em estudo.



7°. Construir uma tabela de frequências dinâmica;

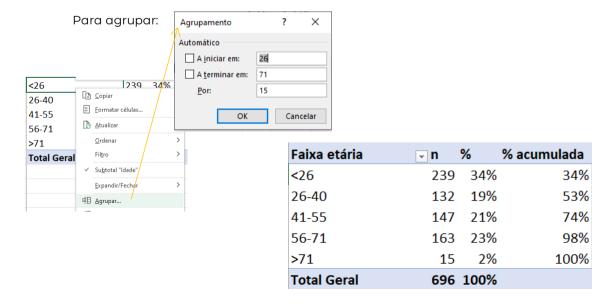
Para construir uma tabela dinâmica começámos por criar uma nova folha de cálculo designada "Tabelas Dinâmicas".





Gravidade da Situaç	%	% acumulada			
Muito boa	6	1%	1%		
Pouca gravidade	147	21%	22%		
Grave	368	53%	75%		
Muito grave	142	20%	95%		
NA	33	5%	100%		
Total Geral	696	100%			

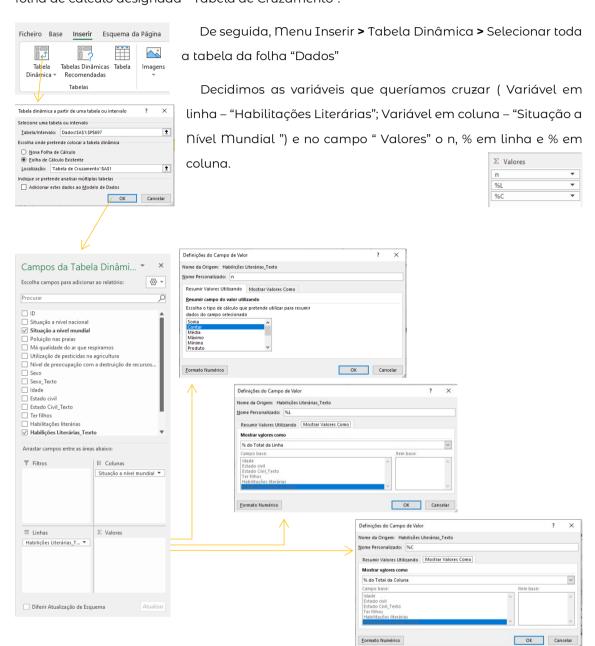
Seguidamente, realizámos de novo todos os passos anteriormente referidos, mas para construir uma tabela com a variável "Idade" de modo a agrupá-la, permitindo assim uma melhor análise desta variável de caracterização social dos inquiridos.



8°. Construir uma tabela de cruzamentos dinâmica;

Tal como na tarefa anterior, começámos por criar uma nova folha de cálculo designada "Tabela de Cruzamento".

Tabela de Cruzamento

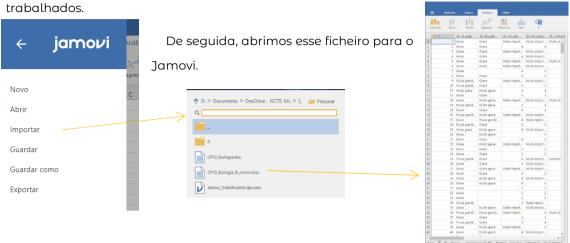


Alterámos os Rótulos das Colunas e de Linhas para os nomes das variáveis em estudo e colocámos 1 casa decimal nas %.

Situação a Nível Mun	dial 🔻														
Muito grave				Grave			Pouca gravidade			NA			Total n	Total %L	Total %C
Habilitações Literárias ▼ n		%L	%C	n	%L	%C	n	%L	%C	n	%L	%C			
Primário	138	52,3%	42,7%	113	42,8%	35,0%		0,0%	0,0%	13	4,9%	43,3%	264	100,0%	37,9%
Secundário	91	35,4%	28,2%	137	53,3%	42,4%	12	4,7%	60,0%	17	6,6%	56,7%	257	100,0%	36,9%
Superior	94	53,7%	29,1%	73	41,7%	22,6%	8	4,6%	40,0%		0,0%	0,0%	175	100,0%	25,1%
Total Geral	323	46,4%	100,0%	323	46,4%	100,0%	20	2,9%	100,0%	30	4,3%	100,0%	696	100,0%	100,0%

II. Jamovi

Para realizar as tarefas propostas no *software* Jamovi e posteriormente no R começámos por criar um Excel exclusivamente com a 1ª folha de cálculo dos dados anteriormente

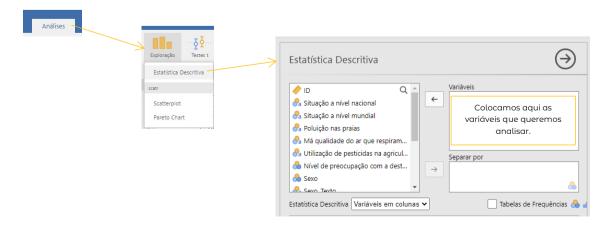


Uma vez que os valores omissos no Jamovi são considerados automaticamente caso a célula esteja em branco, mas no Excel criado anteriormente as não respostas estão como "NA", tivemos de configurar todas as colunas para detetarem as não respostas

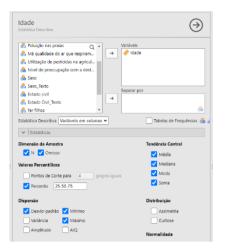


- Construir de forma automática e com recurso ao módulo R:
 - 3 tabelas com medidas descritivas (com 1 e com 2 variáveis)

Para construir as tabelas Análises > Exploração > Estatísticas Descritivas



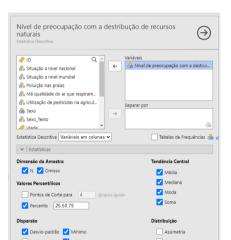
i. Tabela das Medidas Descritivas da "Idade"



Idade

statística Descritiva						
	ldade					
N	696					
Omisso	0					
Média	39.8					
Mediana	37.0					
Moda	24.0					
Soma	27705					
Desvio-padrão	17.2					
Mínimo	18					
Máximo	83					
25º percentil	24.0					
50° percentil	37.0					
75° percentil	56.0					

ii. Tabela das Medidas Descritivas do "Nível de preocupação com a destruição de recursos naturais (0-100)"



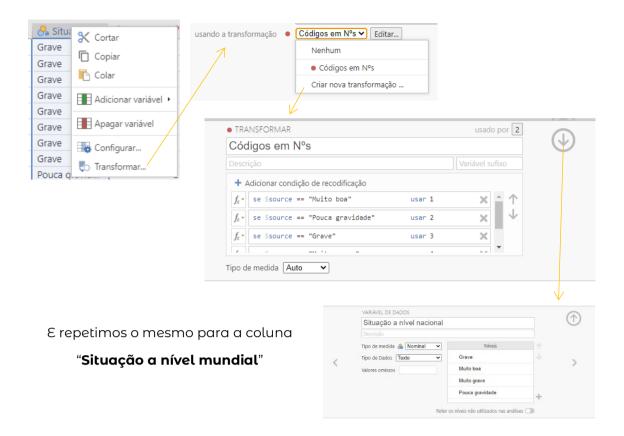
Nível de preocupação com a destribução de recursos naturais

Nível de preocupação com a destruição de recursos naturais (0-100)				
N	690			
Omisso	6			
Média	85.4			
Mediana	86.5			
Moda	100			
Soma	58931			
Desvio-padrão	12.9			
Mínimo	20			
Máximo	100			
25º percentil	77.0			
50° percentil	86.5			
75º percentil	97.0			

iii. Tabela das Medidas Descritivas do "Nível Nacional e Mundial"

Para transformar esta variável qualitativa em quantitativa, de modo a calcular as Medidas Descritivas usamos as potencialidades do Jamovi.

Selecionar a coluna "Situação a nível nacional" > Transformar > Criar Usando a transformação > Criar Nova Transformação > Adicionar condição de Recodificação. Este último passo repete-se tantas vezes quantas designações diferentes a nossa escala possuir ou quantas substituições pretendermos fazer.



Posteriormente, criámos duas tabelas com as duas variáveis em estudo, sendo a 1ª com os códigos em nºs e a 2ª com os códigos em texto.

Situação a Nível Nacional e Mundial

Estatística Descritiva						
	Situação a nível mundial	Situação a nível nacional				
N	666	663				
Omisso	30	33				

Situação a Nível Nacional e Mundial

Estatística Descritiva Situação a nível nacional - Nºs Situação a nível mundial - Nºs 663 666 Omisso 30 33 Mediana 3 3.00 3.00 3.00 a Moda 25º percentil 3.00 3.00 50° percentil 3.00 3.00 3.00 4.00

Frequências

Níveis	Contagens	% do Total	% acumulada
Grave	368	55.5 %	55.5 %
Muito boa	6	0.9 %	56.4 %
Muito grave	142	21.4 %	77.8 %
Pouca gravidade	147	22.2 %	100.0 %

Frequências de \$Key	/		
Níveis	Contagens	% do Total	% acumulada
Grave	323	48.5 %	48.5 %
Muito grave	323	48.5 %	97.0 %
Pouca gravidade	20	3.0 %	100.0 %

^a Existe mais de uma moda, apenas a primeira é apresentada

• 1 gráfico com cruzamento de variáveis

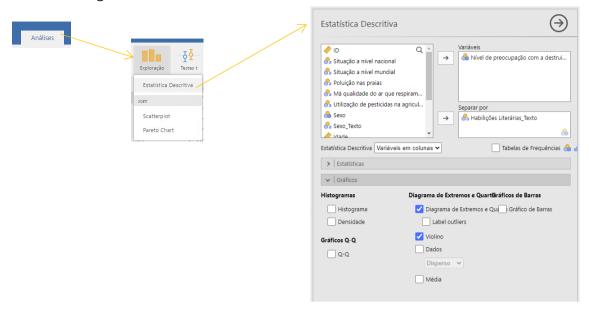


Gráfico de Violinos e de Extremos e Quartis do "Habilitações Literárias" em função do "Nível de Preocupação com a Destruição de Recursos Naturais"

Nível de preocupação com a destruição de recursos naturais (0-100)

